

Sieci neuronowe z szumem: przybliżenie pola średniego


Sieci neuronowe: wykład 05

R.A. Kosiński, T. Gradowski, A. Krawiecki

Politechnika Warszawska
Wydział Fizyki

Neuron formalny z szumem synaptycznym (1)

Uwzględnienie wpływu szumu synaptycznego na dynamikę neuronu



Rysunek: Neuron formalny, zaznaczono opóźnienia potencjałów synaptycznych

Bardziej realistyczny model neuronu polega na

- Uwzględnieniu opóźnień potencjałów czynnościowych τ_{ij} : są to wielkości przypadkowe, związane z różnymi długościami aksonów i różnymi prędkościami propagacji potencjałów czynnościowych wzdłuż synaps,
- Uwzględnieniu przypadkowego charakteru uwalniania neurotransmiterów w połączeniach synaptycznych: w najprostszym przypadku można przyjąć, że po dotarciu potencjału czynnościowego neurotransmitter jest uwalniany i potencjał dociera do następnego neuronu z prawdopodobieństwem p .

Neuron formalny z szumem synaptycznym (2)

Przyjmijmy $\forall i \sigma_i \in \{0, 1\}$, $T_i = 0$.

$$h_i(t) = \sum_j v_{ij}(t)$$

$$v_{ij}(t) = \begin{cases} J_{ij}\sigma_j(t - \tau_{ij}) & \text{z prawdopodobieństwem } p \\ 0 & \text{z prawdopodobieństwem } 1 - p \end{cases},$$

$$\Rightarrow P(v_{ij}) = p\delta(v_{ij} - J_{ij}\sigma_j(t - \tau_{ij})) + (1 - p)\delta(v_{ij}).$$

Z centralnego twierdzenia granicznego Lapunowa wynika, że pole lokalne h_i , jako suma zmiennych losowych o rozkładach dwupunktowych (istnieje wartość oczekiwana i wariancja), jest zmienną losową o rozkładzie normalnym

$$P(h_i) = \frac{1}{\sqrt{2\pi}B^2} \exp \left[-\frac{(h_i - \bar{h}_i)^2}{2B^2} \right],$$

$$\bar{h}_i = E(h_i) = \sum_j E(v_{ij}) = \sum_j \int dv_{ij} P(v_{ij}) v_{ij} = p \sum_j J_{ij}\sigma_j(t - \tau_{ij}),$$

$$B^2 = E \left[(h_i - \bar{h}_i)^2 \right] = p(1 - p) \sum_j J_{ij}^2 \sigma_j(t - \tau_{ij}),$$

(wyprowadzenie pomijamy).

Szum synaptyczny, reprezentowany przez τ_{ij} , p , powoduje, że stan neuronu w chwili t jest zmienną przypadkową o rozkładzie

$$\begin{aligned}P(\sigma_i(t) = +1) &= P(h_i(t) > 0) = \int_0^{\infty} P(h_i) dh_i = \frac{1}{2} \left[1 + \operatorname{erf} \left(\frac{\bar{h}_i}{\sqrt{2}B} \right) \right], \\P(\sigma_i(t) = 0) &= 1 - P(\sigma_i(t) = +1) = \frac{1}{2} \left[1 - \operatorname{erf} \left(\frac{\bar{h}_i}{\sqrt{2}B} \right) \right].\end{aligned}$$

Funkcja aktywacji

$$\mathcal{S} \left(\frac{\bar{h}_i}{\sqrt{2}B} \right) = \operatorname{erf} \left(\frac{\bar{h}_i}{\sqrt{2}B} \right); \quad \beta \equiv \frac{1}{\sqrt{2}B} \Rightarrow \mathcal{S}(\beta \bar{h}_i) = \operatorname{erf}(\beta \bar{h}_i).$$

Średnia wartość neuronu (=średnia aktywność neuronu)

$$\left. \begin{aligned}P(\sigma_i(t) = +1) &= \frac{1}{2} [1 + \mathcal{S}(\beta \bar{h}_i)] \\P(\sigma_i(t) = 0) &= \frac{1}{2} [1 - \mathcal{S}(\beta \bar{h}_i)]\end{aligned} \right| \Rightarrow \bar{\sigma}_i = \sum_{\sigma_i=0,1} P(\sigma_i(t)) \sigma_i = \frac{1}{2} [1 + \mathcal{S}(\beta \bar{h}_i)]$$

Dla $\sigma_i \in \{-1, 1\}$

Średnia wartość neuronu (=średnia aktywność neuronu)


$$\begin{aligned} P(\sigma_i(t) = +1) &= \frac{1}{2} \left[1 + \mathcal{S}(\beta \bar{h}_i) \right] \\ P(\sigma_i(t) = -1) &= \frac{1}{2} \left[1 - \mathcal{S}(\beta \bar{h}_i) \right] \end{aligned} \quad \Bigg| \Rightarrow P(\sigma_i(t)) = \frac{1}{2} [1 + \sigma_i(t) \mathcal{S}(\beta \bar{h}_i)]$$

$$\bar{\sigma}_i = \sum_{\sigma_i = \pm 1} P(\sigma_i(t)) \sigma_i = \mathcal{S}(\beta \bar{h}_i)$$

Można wprowadzić inne funkcje aktywacji, nieparzyste, spełniające warunek
 $\lim_{x \rightarrow \pm\infty} = \pm 1$,

- $\mathcal{S}(x) = \tanh(x)$ (dla szumu termicznego)
- $\mathcal{S}(x) = \frac{x}{\sqrt{x^2 + 1}}$,
- $\mathcal{S}(x) = -1$ dla $x < -1$, $\mathcal{S}(x) = x$ dla $-1 \leq x \leq 1$, $\mathcal{S}(x) = 1$ dla $x > 1$, ...

Neuron formalny z szumem synaptycznym (5)



Rysunek: Porównanie różnych rodzajów funkcji sigmoidalnych $S(x)$. Funkcja $\tanh(x)$ przybliża funkcję $\text{erf}(x)$ z dokładnością do 1%. Właściwości sieci neuronowych nie powinny być zależne od drobnych zmian funkcji aktywacji. Wykorzystanie przybliżenia funkcji aktywacji $S(x) = \tanh(x)$ pozwala natomiast na użycie całego aparatu fizyki statystycznej.

Metoda Monte Carlo symulacji asynchronicznej dynamiki sieci neuronowej z szumem

Pełny krok symulacji Monte Carlo (MCSS)


- (1) Wybierz przypadkowo neuron i (bez powtórzeń),
- (2) Oblicz pole lokalne $h_i(t-1) = \sum_j J_{ij} \sigma_j(t-1)$,
- (3) Zaktualizuj stan neuronu i : $\sigma_i(t) = \sigma \in \{-1, +1\}$ z prawdopodobieństwem $P(\sigma) = \frac{1}{2} [1 + \sigma \mathcal{S}(\beta h_i(t-1))]$,
- (4) Iteruj od (1) do chwili zaktualizowania stanów wszystkich neuronów.

Uwaga: Pełny krok symulacji MC stanowi sekwencję N "małych" kroków; w każdym "małym" kroku używamy aktualnych stanów neuronów, w szczególności stanów neuronów zaktualizowanych w poprzednich "małych" krokach danego pełnego kroku.

Uwaga: punkt (3) można w sposób równoważny zapisać

- (3) Odwróć stan neuronu i z prawdopodobieństwem $w_i = \frac{1}{2} [1 - \sigma_i(t-1) \mathcal{S}(\beta h_i(t-1))]$.

$$\begin{aligned} P(\sigma_i(t) = +1) &= P(\sigma_i(t-1) = -1) \frac{1}{2} [1 + \mathcal{S}(\beta h_i(t-1))] \\ &+ P(\sigma_i(t-1) = +1) \left\{ 1 - \frac{1}{2} [1 - \mathcal{S}(\beta h_i(t-1))] \right\} \\ &= \frac{1}{2} [1 + \mathcal{S}(\beta h_i(t-1))], \text{ itd.} \end{aligned}$$



Rysunek: Możliwe przejścia do (ze) stanu $J = (+1, +1, -1)$ zaznaczono strzałkami

Przykład: $N=3$ neurony

- Możliwe 2^N stanów sieci można przedstawić jako wierzchołki (hiper)sześcianu w przestrzeni N -wymiarowej,
- Trajektoria fazowa $I(t) = \{\sigma_i(t)\}$ przebiega wierzchołki (hiper)sześcianu,
- Pojedynczy ("mały") krok czasowy symulacji polega na zmianie stanu co najwyżej jednego neuronu, np. możliwe jest przejście ze stanu $J = (+1, +1, -1)$ do stanu $I = (+1, -1, -1)$ z prawdopodobieństwem $w(I|J)$,
- Na (hiper)sześcianie oznacza to przejście do (z) jednego ze stanów (I) sąsiadujących ze stanem J ,
- Dla każdego stanu istnieje tylko jeden stan sąsiedni, różniący się stanem jednego (i tylko tego) wybranego neuronu.

- Niech $\rho(I, t)$ oznacza prawdopodobieństwo, że w chwili t sieć jest w stanie I ,
- Niech $w(I|J)$ oznacza prawdopodobieństwo warunkowe, że w chwili t sieć jest w stanie I , jeśli w chwili $t - 1$ była w stanie J ,
- Ze wzoru na prawdopodobieństwo warunkowe otrzymujemy **równanie Master**

$$\rho(I, t) = \sum_J w(I|J) \rho(J, t - 1).$$

Dla dynamiki Glaubera sieć w stanie J w jednym "małym" kroku czasowym może

- Przejść do stanu I różniącego się od stanu J orientacją jednego neuronu, np. $\sigma_i(I) = -\sigma_i(J)$ wskutek
 - Wybrania neuronu i spośród N neuronów, z prawdopodobieństwem $1/N$,
 - Zaktualizowania stanu neuronu $\sigma_i(J)$ do $\sigma_i(I)$, z prawdopodobieństwem $P(\sigma_i(I)) = \frac{1}{2} [1 + \sigma_i(I) S(\beta h_i(J))]$
- Pozostać w stanie J .

$$\begin{aligned} W(I|J) &= \frac{1}{N} P(\sigma_i(I)) = \frac{1}{2N} [1 + \sigma_i(I) S(\beta h_i(J))], \\ W(J|J) &= 1 - \sum_{I \neq J} W(I|J) \end{aligned}$$

W powyższych wzorach I oznacza jeden z N stanów sieci, różniących się od J stanem tylko jednego neuronu.

Równanie na średnią aktywność neuronu

Uśredniony po zespole stan (aktywność) neuronu i w chwili t wynosi

$$\begin{aligned}\langle \sigma_i(t) \rangle &= \sum_I \sigma_i(I) \rho(I, t), \\ \Rightarrow \langle \sigma_i(t+1) \rangle &= \sum_I \sigma_i(I) \rho(I, t+1) = \sum_I \sigma_i(I) \left(\sum_J w(I|J) \rho(J, t) \right) \\ &= \sum_J \left(\sum_I w(I|J) \sigma_i(I) \right) \rho(J, t) = \left\langle \sum_I w(I|J) \sigma_i(I) \right\rangle.\end{aligned}$$

Niech

$$F_i(J) \equiv \sum_I w(I|J) \sigma_i(I) \Rightarrow \langle \sigma_i(t+1) \rangle - \langle \sigma_i(t) \rangle = -(\langle \sigma_i(t) \rangle - \langle F_i(t) \rangle)$$

Zapis w formie równania różniczkowego daje (τ jest stałą proporcjonalności)

$$\frac{d\langle \sigma_i \rangle}{dt} = -\frac{1}{\tau} (\langle \sigma_i(t) \rangle - \langle F_i(t) \rangle). \quad (1)$$

$$F_i(J) = \sum_I w(I|J) \sigma_i(I) = w(J|J) \sigma_i(J) + \sum_{I \neq J} w(I|J) \sigma_i(I) =$$

$$\sigma_i(J) - \sum_{I \neq J} \frac{1}{2N} [1 + \sigma_i(I) S(\beta h_i(J))] \sigma_i(J) + \sum_{I \neq J} \frac{1}{2N} [1 + \sigma_i(I) S(\beta h_i(J))] \sigma_i(I).$$

- W ostatniej linijce suma przebiega po stanach I , różniących się od stanu $J = (\sigma_1(J), \dots, \sigma_i(J), \dots, \sigma_N(J))$ orientacją tylko jednego neuronu,
- Wśród ww. stanów jest tylko jeden $I = J^{i,R} = (\sigma_1(J), \dots, -\sigma_i(J), \dots, \sigma_N(J))$, różniący się od J orientacją neuronu i ,
- $I = J^{i,R} \Rightarrow \sigma_i(I) = -\sigma_i(J) \Rightarrow \sigma_i(I) \sigma_i(J) = -1$; $I \neq J^{i,R} \Rightarrow \sigma_i(I) \sigma_i(J) = 1$; $\sigma_i(I) \sigma_i(I) = 1$, więc znoszą się wszystkie wyrazy w obu sumach poza jednym, dla $I = J^{i,R}$.

$$F_i(J) = \sigma_i(J) - \frac{1}{N} [\sigma_i(J) - S(\beta h_i(J))]$$

Ścisłe równanie dla średniej wartości (aktywności) neuronu

$$\frac{d\langle \sigma_i \rangle}{dt} = -\frac{1}{\tau_r} [\langle \sigma_i(t) \rangle - \langle S(\beta h_i) \rangle], \quad \tau_r = N\tau \quad (2)$$

Interludium: dlaczego dynamika Glaubera, $\mathcal{S}(x) = \tanh(x)$ i szum termiczny?

Przykład: dynamika Glaubera dla sieci Hopfielda z szumem termicznym

Niech stany sieci I, J różnią się stanem neuronu i , tj. $\sigma_i(I) = -\sigma_i(J)$.

$$\left. \begin{aligned} H(I) &= - \sum_{\langle ij \rangle} J_{ij} \sigma_i(I) \sigma_j(J) \\ H(J) &= - \sum_{\langle ij \rangle} J_{ij} \sigma_i(J) \sigma_j(J) \end{aligned} \right| \Rightarrow H(J) - H(I) = 2\sigma_i(I) \sum_j J_{ij} \sigma_j(J) = 2\sigma_i(I) h_i(J).$$

$$W(I|J) = \frac{1}{2^N} [1 + \sigma_i(I) \tanh(\beta h_i(J))] = \frac{1}{2^N} [1 + \tanh(\beta \sigma_i(I) h_i(J))],$$

$$\frac{1}{2}(1 + \tanh x) = \frac{e^x}{2 \cosh x} \Rightarrow W(I|J) = \frac{\exp\left\{\frac{\beta}{2} [H(J) - H(I)]\right\}}{2^N \cosh\left\{\frac{\beta}{2} [H(J) - H(I)]\right\}}$$

$$\Rightarrow \frac{W(I|J)}{W(J|I)} = \frac{\exp\left\{\frac{\beta}{2} [H(J) - H(I)]\right\}}{\exp\left\{\frac{\beta}{2} [H(I) - H(J)]\right\}} = \frac{\exp[-\beta H(I)]}{\exp[-\beta H(J)]}$$

$$W(I|J) \exp[-\beta H(J)] = W(J|I) \exp[-\beta H(I)]$$

Dynamika Glaubera z szumem termicznym spełnia postulat równowagi szczegółowej

Wniosek: $\rho(I) = \frac{1}{Z} \exp[-\beta H(I)]$ – rozkład Boltzmanna.

- **Przybliżenie pola średniego** oznacza założenie, że korelacje pomiędzy zmiennymi zależnymi od stanu układu można zaniedbać. Dla rozkładu prawdopodobieństwa stanów sieci $I = \{\sigma_i\}$ oznacza to

$$\rho(I) = \prod_i \rho_i(\sigma_i), \quad \sum_{\sigma_i=\pm 1} \rho_i(\sigma_i) = 1,$$

gdzie $\rho_i(\sigma_i)$ jest rozkładem prawdopodobieństwa, że neuron i jest w stanie σ_i .

- Wartość oczekiwana dwóch wielkości $O_i(I)$, $O_j(I)$, zależnych tylko od stanów neuronów i, j , jest wówczas iloczynem wartości oczekiwanych,

$$\begin{aligned} \langle O_i O_j \rangle &= \sum_I \rho(I) O_i(\sigma_i) O_j(\sigma_j) = \\ &= \left[\sum_{\sigma_i=\pm 1} \rho_i(\sigma_i) O_i(\sigma_i) \right] \left[\sum_{\sigma_j=\pm 1} \rho_j(\sigma_j) O_j(\sigma_j) \right] \prod_{k \neq i, j} \left[\sum_{\sigma_k=\pm 1} \rho_k(\sigma_k) \right] = \langle O_i \rangle \langle O_j \rangle. \end{aligned}$$

W przybliżeniu pola średniego $\langle h_i^2 \rangle = \langle h_i \rangle \langle h_i \rangle = \langle h_i \rangle^2$, więc

$$\begin{aligned}\langle \mathcal{S}(h_i) \rangle &= \left\langle \mathcal{S}[\langle h_i \rangle + (h_i - \langle h_i \rangle)] \right\rangle \\&= \mathcal{S}(\langle h_i \rangle) + \underbrace{\langle h_i - \langle h_i \rangle \rangle}_{=\langle h_i \rangle - \langle h_i \rangle = 0} \mathcal{S}'(\langle h_i \rangle) + \frac{1}{2} \underbrace{\langle (h_i - \langle h_i \rangle)^2 \rangle}_{=\langle h_i^2 \rangle - 2\langle h_i \rangle \langle h_i \rangle + \langle h_i \rangle^2 = 0} \mathcal{S}''(\langle h_i \rangle) + \dots \\&= \mathcal{S}(\langle h_i \rangle)\end{aligned}$$

Równanie dla wartości średniej neuronu w przybliżeniu pola średniego

$$\frac{d\langle \sigma_i \rangle}{dt} = -\frac{1}{\tau_r} [\langle \sigma_i(t) \rangle - \mathcal{S}(\langle h_i \rangle)], \quad (3)$$

Interludium: przybliżenie pola średniego dla modelu Isinga, $S(x) = \tanh x$

Przykład: przejście ferromagnetyczne

$$H = - \sum_{\langle ij \rangle} J_{ij} \sigma_i \sigma_j; \quad J_{ij} = \frac{J}{N}, \quad J = \text{const} > 0,$$


$$h_i = \frac{J}{N} \sum_{j \neq i} \sigma_j.$$

Magnetyzacja $M = \langle \sigma_j \rangle$, wszystkie spiny równoważne \Rightarrow z równ. (3)

$$\frac{dM}{dt} = -\frac{1}{\tau_r} [M - \tanh(\beta JM)],$$

Punkty stałe spełniają warunek $\frac{dM}{dt} = 0$ i odpowiadają fazom

- paramagnetycznej, $M = 0$,
- ferromagnetycznej, $|M| > 0$,
wyznaczane z równania
 $M = \tanh(\beta JM)$, istnieją dla $\beta_c > J^{-1}$.



W okolicy $\beta = \beta_c = 1/J$ zachodzi $M \approx 0$ i można rozwinąć $\tanh(x) \approx x - \frac{1}{3}x^3$,

$$M \approx \beta JM [1 - \frac{1}{3}(\beta JM)^2] \Rightarrow$$

$$M = 0 \text{ lub } M = \beta^{-1} \sqrt{3 [1 - (\beta J)^{-1}]}.$$

Dwa symetryczne rozwiązania niezerowe istnieją dla $\beta > \beta_c = J^{-1}$.

Przybliżenie pola średniego dla sieci Hopfielda z szumem (1)

Dla sieci Hopfielda

$$J_{ij} = \frac{1}{N} \sum_{\mu=1}^P \xi_i^{\mu} \xi_j^{\mu} \Rightarrow \langle h_i \rangle = \sum_{j=0}^N J_{ij} \langle \sigma_j \rangle = \sum_{\mu=1}^P \xi_i^{\mu} \frac{1}{N} \left[\sum_{j=1}^N \xi_j^{\mu} \langle \sigma_j \rangle \right].$$

Średnie przekrycie ze wzorcem ξ^{μ}

$$M^{\mu} = \frac{1}{N} \sum_{i=1}^N \xi_i^{\mu} \langle \sigma_i \rangle \Rightarrow \langle h_i \rangle = \sum_{\mu=1}^P \xi_i^{\mu} M^{\mu}.$$

Równanie dla średniej wartości (aktywności) neuronu w przybliżeniu pola średniego

$$\frac{d\langle \sigma_i \rangle}{dt} = -\frac{1}{\tau_r} \left[\langle \sigma_i(t) \rangle - \mathcal{S} \left(\sum_{\mu=1}^P \xi_i^{\mu} M^{\mu} \right) \right],$$

Równanie dla średnich przekryć w przybliżeniu pola średniego

$$\frac{dM^{\mu}}{dt} = \frac{1}{N} \sum_{i=1}^N \xi_i^{\mu} \frac{d\langle \sigma_i \rangle}{dt} = -\frac{1}{\tau_r} \left[M^{\mu} - \frac{1}{N} \sum_{i=1}^N \xi_i^{\mu} \mathcal{S} \left(\beta \sum_{\mu'=1}^P \xi_i^{\mu'} M^{\mu'} \right) \right]. \quad (4)$$

Przybliżenie pola średniego dla sieci Hopfielda z szumem (2)

- Równ. (4) posiada m. in. rozwiązania $\tilde{M} = (0, \dots, 0, M^\nu(t), 0, \dots, 0)$, odpowiadające przekryciu z zapamiętanym wzorcem ξ^ν . Powinny to być najbardziej stabilne rozwiązania.
- Przyjmując warunek początkowy $M^\nu(0) \neq 0$, $M^\mu(0) = 0$, $\mu \neq \nu$, możemy ograniczyć się do badania tylko takich rozwiązań,

$$\frac{dM^\nu}{dt} = -\frac{1}{\tau_r} \left[M^\nu - \frac{1}{N} \sum_{i=1}^N \xi_i^\nu \mathcal{S}(\beta \xi_i^\nu M^\nu) \right]. \quad (5)$$

- **Punkty stałe** równ. (5) są to rozwiązania niezależne od czasu, spełniające warunek $\frac{dM^\nu}{dt} = 0$, czyli

$$M^\nu = \frac{1}{N} \sum_{i=1}^N \xi_i^\nu \mathcal{S}(\beta \xi_i^\nu M^\nu). \quad (6)$$

- Ponieważ $\mathcal{S}(0) = 0$, równ. (6) posiada rozwiązanie $M^\nu = 0$. Odpowiada ono brakowi przekrycia z zapamiętanym wzorcem, czyli utracie pamięci przez sieć przy dużym szumie $\beta \ll 1$ (stanowi paramagnetycznemu).
- Przy niskim szumie $\beta \gg 1$ istnieją rozwiązania niezerowe, $|M^\nu| > 0$, odpowiadające rozpoznaniu zapamiętanego wzorca (stanowi ferromagnetycznemu).

Rozważmy sieć Hopfielda z szumem termicznym, $\mathcal{S}(x) = \tanh(x)$.

Przy dużych szumach (wysokich temperaturach, $\beta \ll 1$) powinno zachodzić $M^\nu \approx 0$ i w równ. (6) można wykorzystać przybliżenie $\mathcal{S}(x) = \tanh(x) \approx x - \frac{1}{3}x^3$,

$$M^\nu = \frac{1}{N} \sum_{i=1}^N \xi_i^\nu \left(\beta \xi_i^\nu M^\nu - \frac{1}{3} (\beta \xi_i^\nu M^\nu)^3 \right) = M^\nu \beta \left(1 - \frac{1}{3} (\beta M^\nu)^2 \right). \quad (7)$$

Równ. (7) ma rozwiązania

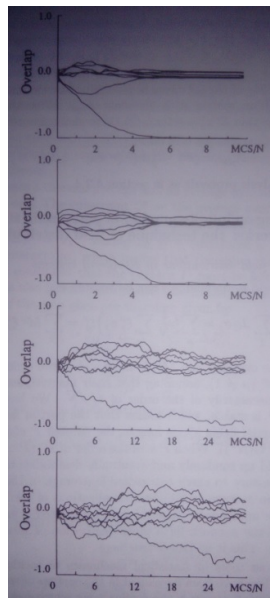
$$\begin{aligned} M^\nu &= 0 \\ M^\nu &= \pm \sqrt{\frac{3(\beta - 1)}{\beta^3}} \end{aligned} \quad (8)$$

- Rozwiązanie (8) odpowiada stanowi ferromagnetycznemu i rozpoznaniu wzorca,
- Rozwiązanie ferromagnetyczne istnieje dla temperatur niższych od **temperatury krytycznej** $\beta > \beta_c = 1$ ($\beta^{-1} < \beta_c^{-1} = 1$),
- Uwaga: dla $\mathcal{S}(x) = \text{erf}(x)$ analogiczne przybliżenia dają $\beta_c = \frac{2}{\sqrt{\pi}}$.

Przybliżenie pola średniego dla sieci Hopfielda z szumem (4)

Dla $\beta > 1$ rozwiązania ferromagnetyczne (8) są **stabilnymi** atraktorami punktowymi, tj. mają niezerowe obszary przyciągania.

Rysunek: Wpływ szumu na rozpoznawanie wzorca w sieci Hopfielda z $N = 400$ neuronami. Zapamiętano 8 nieskorelowanych wzorców, na rysunku przedstawiono przekrycie obserwowanego stanu sieci $I(t)$ z każdym ze wzorców. Dynamika Glaubera z szumem termodynamicznym. Temperatury (od góry) $\beta^{-1} = 0, 0.50, 0.80, 0.95$. Widać zmniejszenie szybkości rozpoznania wzorca (critical slowing down) i wartości przekrycia ze wzrostem temperatury (dla sieci z szumem termicznym $\beta_c^{-1} = 1.0$).



Przybliżenie pola średniego dla sieci Hopfielda z szumem (5)

- Dla $\beta < 1$ układ równań (4) ma również inne punkty stałe, w ogólności odpowiadające **stanom pasożytniczym**, tj. kombinacjom liniowym zapamiętanych wzorców,
- Na przykład można łatwo wykazać, że istnieją punkty stałe w postaci symetrycznych kombinacji q wzorców zapamiętanych ($q \leq P$),

$$M^\mu = \frac{M}{\sqrt{q}}, \mu = 1, 2, \dots, q; \quad M^\mu = 0, \mu = q + 1, q + 2, \dots, P.$$

Takie punkty stałe mają węższy zakres stabilności niż stany ferromagnetyczne, np.

- stany z q parzystymi są niestabilne,
- stany z $q = 3$ są stabilne dla $\beta^{-1} < 0.461$ (najbardziej stabilne stany pasożytnicze),
- stany z $q = 5$ są stabilne dla $\beta^{-1} < 0.385, \dots$
- Istnieją również punkty stałe w postaci niesymetrycznych kombinacji zapamiętanych wzorców, o różnym zakresie stabilności.

Badanie stabilności punktów statych układu równań (4) odbywa się standardowymi metodami, znanymi np. z wykładu Dynamika układów nieliniowych, ale jest dość czasochłonne ze względu na konieczność uśredniania po wszystkich neuronach w sieci i po różnych realizacjach zapamiętanych wzorców; szczegóły można znaleźć w pracy **D. J. Amit, H. Gutfreund, H. Sompolinsky, *Phys. Rev. A* **32**, 1007 (1985).**

Stany pasożytnicze

W niskich temperaturach (przy małym szumie) sieć może osiąść w stanie pasożytniczym.

Rysunek: Rozpoznawanie wzorca w sieci Hopfielda z $N = 100$ neuronami. Zapamiętano 8 nieskorelowanych wzorców, na rysunku przedstawiono przekrycie obserwowanego stanu sieci $I(t)$ z każdym ze wzorców. Dynamika Glaubera bez szumu, $\beta^{-1} = 0$. W zależności od stanu początkowego $I(0)$ sieć prawidłowo rozpoznaje jeden z zapamiętanych wzorców (góra) lub ewoluuje w stronę stanu pasożytniczego, będącego mieszaniną 3 zapamiętanych wzorców. Kombinacje liniowe 3 zapamiętanych wzorców są najbardziej stabilnymi stanami pasożytniczymi.

